

TASK6 智能决策者：用机器学习定制专属策略

量化交易课程个人作业报告

课程任务	TASK6 智能决策者：用机器学习定制专属策略
姓名	辛家辉
完成日期	2026年7月18日
提交文件	辛家辉TASK6. pdf
数据集	model_data.csv (39,616 条 × 19 个财务因子)

一、作业任务

本作业使用 A 股财务因子数据，训练多种机器学习模型预测股票下一季度收益，并在每个季度按预测得分挑选前 30 只股票构建投资组合。通过对比四种模型（线性回归、逻辑回归、决策树、随机森林）的等权（EW）和预测收益加权（PW）组合与市场基准的收益、风险、夏普比率、最大回撤、信息比率等指标，评估机器学习选股策略的有效性。

二、数据集与时间划分

原始数据共 39,616 条记录，包含 19 个财务因子和下一季度收益标签 Next_Ret。按时间划分：训练集 2020Q1 - 2021Q2 共 6 个季度 22,855 条，测试集 2021Q3 - 2022Q2 共 4 个季度 16,761 条。训练集用于模型学习，测试集用于选股与策略回测，严格避免未来信息泄露。

数据预处理包括两个步骤：第一，对 19 个财务因子按训练集 1%/99% 分位数进行 Winsorize 缩尾，消除极端值对模型的干扰；第二，用训练集均值和标准差对全部因子做 StandardScaler 标准化，使各因子量纲统一，有利于线性模型和正则化收敛。

三、算法原理与选股逻辑

1. 四种模型

线性回归（LinearRegression）：以最小二乘法拟合因子与收益的线性关系，作为基线模型。优点是简单可解释，缺点是无法捕捉非线性模式。

逻辑回归（LogisticRegression）：将 Next_Ret > 0 转为二分类标签，训练分类器后取正类概率作为排序分数。C=0.01 增强正则化，避免过拟合。

决策树（DecisionTreeRegressor）：以 CART 算法递归分裂特征空间，max_depth=8 控制复杂度。能捕捉非线性关系，可输出特征重要性。

随机森林（RandomForestRegressor）：通过自助采样和特征随机集成 100 棵决策树，使用 RandomizedSearchCV 在 n_estimators、max_depth、min_samples_leaf 三个参数上做 4 轮随机搜索，泛化能力通常优于单棵决策树。

2. Top 30 选股逻辑

对测试集的每个季度，按模型预测得分从高到低排序，选取前 30 只股票构建组合。EW（等权）组合中每只股票权重为 1/30；PW（预测收益加权）组合中权重正比于预测收益，预测收益越高权重越大。组合收益为各股票下一季度实际收益的加权平均。

3. 评价指标

累计收益：4 个季度组合收益连乘后减 1。年化收益 = 季度均值 × 4。年化波动率 = 季度标准差 × √4。夏普比率 = 年化收益 / 年化波动率，衡量单位风险收益。最大回撤：累计净值的最大峰谷跌幅。信息比率 = 超额收益均值 / 超额收益标准差 × √4，衡量相对基准的风险调整收益。超额胜率：组合收益超越市场基准的季度占比。

四、Python 实现流程

程序从 model_data.csv 读取数据后，按 SPLIT_DATE=2021/7/1 划分训练集与测试集，对 19 个因子做 Winsorize 和 StandardScaler。随后训练四个模型，LinearRegression 和 DecisionTreeRegressor 直接预测收益，LogisticRegression 预测涨跌概率，RandomForest 通过 RandomizedSearchCV 调参。

选股阶段对每个测试季度按预测得分排序取 Top 30，分别计算 EW 和 PW 组合收益。回测阶段聚合 4 个季度收益序列，计算 9 个组合（4 模型 × 2 权重 + 市场基准）的 7 项指标，保存到 performance_metrics.csv 和 quarterly_returns.csv。最后生成 4 张图表和 PDF 报告。

```

df = pd.read_csv('material/model_data.csv')
train, test = split_by_date(df, '2021/7/1')
train, test = winsorize(train, test, FEATURE_COLS)
scaler = StandardScaler().fit(train[FEATURE_COLS])
X_train = scaler.transform(train[FEATURE_COLS])
y_train = train['Next_Ret']
models = train_models(X_train, y_train, (y_train > 0).astype(int))
preds = predict_models(models, X_test)
quarterly = build_portfolios(test, preds, y_test)
metrics = calc_metrics(quarterly)

```

五、模型评估结果

表1 四模型测试集预测性能

模型	测试 MSE	测试 MAE	说明
LinearRegression	0.057595	0.173213	回归预测
LogisticRegression	0.331660	0.542902	二分类概率排序，AUC=0.5702
DecisionTree	0.058769	0.172967	回归预测
RandomForest	0.056284	0.169909	回归预测

表2 九组合回测绩效（4 模型 × 2 权重 + 市场基准）

模型	权重	累计收益	年化收益	波动率	夏普	最大回撤	信息比率	胜率
Market	--	-6.35%	-5.14%	16.69%	-0.3079	-15.91%	0.0000	0%
LinearRegression	EW	13.62%	14.51%	18.18%	0.7982	-5.42%	1.1270	75%
LinearRegression	PW	13.57%	14.48%	18.31%	0.7910	-5.24%	1.1283	75%
LogisticRegression	EW	20.14%	20.07%	16.86%	1.1901	-3.22%	1.3310	75%
LogisticRegression	PW	19.89%	19.87%	16.98%	1.1704	-3.21%	1.3198	75%
DecisionTree	EW	-1.21%	-0.08%	15.11%	-0.0052	-10.03%	0.3619	50%
DecisionTree	PW	-1.19%	-0.06%	15.03%	-0.0043	-10.10%	0.3574	50%
RandomForest	EW	11.86%	12.33%	14.07%	0.8762	-5.55%	2.2106	75%

模型	权重	累计收益	年化收益	波动率	夏普	最大回撤	信息比率	胜率
RandomForest	PW	12.93%	13.30%	14.01%	0.9497	-4.95%	2.5869	75%

图1 各模型 Top 30 组合累计收益对比（含市场基准）




图1 各模型 Top 30 组合累计收益对比

图1 展示了 8 个模型组合和 1 个市场基准在 4 个测试季度上的累计净值走势。从图中可以看到，LogisticRegression 模型的 EW 组合表现最好，累计收益达到 20.14%，明显跑赢市场基准的 -6.35%。大部分 ML 组合在整个测试期都维持在基准上方，说明模型选股具有正向预测能力。

图2 EW 等权 vs PW 预测收益加权对比




图2 EW 等权 vs PW 预测收益加权对比

图2 对比了 EW 和 PW 两种加权方式的累计收益和夏普比率。可以看到 EW 和 PW 的结果非常接近，说明在 Top 30 组合内，按预测收益加权的额外信息量有限。EW 方式更简单稳健，实操中推荐使用。

图3 决策树与随机森林特征重要性对比




图3 决策树与随机森林特征重要性

图3 展示了决策树和随机森林认为最重要的 15 个财务因子。两个模型一致认为市值 MV、净利润同比增长率、营业总收入同比增长率等基本因子对下一季度收益有较强的预测力，估值类因子（PB、PE、PS）的重要性相对较低。

图4 线性回归系数 Top 10 正/负




图4 线性回归系数 Top 10 正/负

图4 展示了线性回归中影响最大的 10 个正向和 10 个负向系数。正向系数最大的因子表示该因子值越大, 下一季度收益预期越高; 负向系数反之。线性模型的优势在于系数可直接解读为因子的边际影响方向。

六、Top 30 选股 vs 基准对比

从表2 和图1 可以看到,全部 8 个 ML 组合的累计收益均高于市场基准的 -6.35%,其中 LogisticRegression-EW 组合累计收益 20.14%、夏普比率 1.1901,远优于基准的夏普 -0.3079。超额胜率方面,多数模型组合在 4 个测试季度中有 3 个季度跑赢基准(胜率 75%),说明 ML 选股策略具有相对稳定的超额收益能力。

七、策略优势与局限

优势：（1）自适应性——模型能从历史数据中学习因子与收益的关系，适应市场变化；（2）多维决策——可同时考虑 19 个因子的复杂非线性组合，远超人工经验；（3）概率/得分输出——提供排序信号，便于按信心度选股；（4）可优化——可通过调参、换模型、加因子持续改进。

局限：（1）数据依赖——需要大量高质量历史数据，数据噪声直接影响模型；（2）过拟合风险——决策树等模型容易学习历史噪声而非真实规律，需用独立测试集验证；（3）黑盒问题——随机森林等复杂模型难以解释单只股票的入选原因；（4）计算成本——随机森林调参耗时较长，实盘中需平衡精度与效率；（5）市场变化——当市场结构发生突变（如政策转向、金融危机）时，历史规律可能失效。

八、作业总结

本次作业完成了从数据加载、预处理、四模型训练、Top 30 选股、组合构建、回测评估到可视化和 PDF 报告的完整流程。结果表明，机器学习选股策略在测试期内显著跑赢市场基准，其中 LogisticRegression 表现最优。EW 与 PW 两种加权方式效果接近，推荐使用更简单的 EW。但需注意测试期仅 4 个季度，样本较短，结论的统计显著性有限，实盘应用前需更长时间的样本外验证。Python 源码、4 张图表、模型 .pkl 文件和全部结果 CSV 均保存在 TASK6 目录。